

차원 축소 기법 훑어보기

PCA, SVD, NMF

최범균, 2014-04-25

	i1	i2	i3	...	i11998	i11999	i12000
u1	0	0	0	...	1	0	0
u2	1	0	0	...	0	0	0
u3	1	0	1	...	0	0	1
...
u499998	0	0	0	...	0	0	0
u499999	0	0	0	...	0	1	0
u500000	0	0	0	...	0	0	0

u간 또는 i간 유사도를 구하려면?
 많은 계산 필요, 0이 너무 많음

차원 축소가 필요한 이유

- 계산 비용 축소
- 노이즈 제거
- 도출된 결과 이해

차원 축소 알고리즘 몇 가지

- 주요 구성요소 분석(principal component analysis; PCA)
- 특이 값 분해(Singular Value Decomposition; SVD)
- 비음수 행렬 인수분해(Non-negative Matrix Factorization; NMF)

* “머신러닝 인 액션”과 “집단 지성 프로그래밍” 책 참고

1. PCA

주요 구성요소 분석(PCA)

- PCA란?
 - 데이터에서 두드러지게 데이터를 나누는
- PCA를 이용하면,
 - 중요한 속성 도출
 - 데이터 압축
 - 얼굴 인식(eigenface)
 - 기타 등등

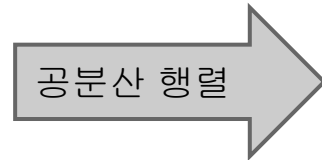
PCA 구하기 과정 요약

- 데이터 집합에 대해 공분산 행렬 구함
 - 데이터의 집합의 각 열을 데이터의 속성이라고 가정
 - 즉, 열이 n 개면, 속성 x_1, x_2, \dots, x_n 개 존재
- 공분산 행렬에서 고유값과 고유벡터 구함
- 고유값 목록에서 값이 높은 k 개 인덱스 구함
 - 인덱스 값이 i_1, i_2, \dots, i_k 라고 할 경우
 - $x_{i_1}, x_{i_2}, \dots, x_{i_k}$ 가 주요 구성요소가 됨

PCA 구하기 1: 공분산 행렬 구하기

데이터 행렬: 세 개의 속성

x1	x2	x3
2	1	3
8	4	7
1	4	4
2	8	2



Cov(x1, x1) 10.25	Cov(x1, x2) -0.41666667	Cov(x1, x3) 6
Cov(x2, x1) -0.41666667	Cov(x2, x2) 8.25	Cov(x2, x3) -1.66666667
Cov(x3, x1) 6	Cov(x3, x2) -1.66666667	Cov(x3, x3) 4.66666667


* 공분산: $\text{Cov}(X, Y) = (\sum (x - x_{\text{평균}})(y - y_{\text{평균}})) / (n - 1)$

* $\text{Cov}(X, X) = \text{Var}(X)$, 즉 분산

PCA 구하기2: 고유값 구하기

- 공분산 행렬에서 고유값, 고유벡터 구함

Cov(x1, x1) 10.25	Cov(x1, x2) -0.41666667	Cov(x1, x3) 6
Cov(x2, x1) -0.41666667	Cov(x2, x2) 8.25	Cov(x2, x3) -1.66666667
Cov(x3, x1) 6	Cov(x3, x2) -1.66666667	Cov(x3, x3) 4.66666667



고유값 목록:
[0.6541291, 14.33608183, 8.17645574]

고유벡터 목록:

0.51879659	0.81567701	0.25597093
-0.15597286	-0.20408152	0.96644876
-0.84054897	0.54131484	-0.02134668


* n차 정사각 행렬 A가 있을 때, 고유벡터V와 고유값 λ 의 관계: $AV = V\lambda$

PCA 구하기3: 고유값 목록에서 주요 구성요소 뽑기

x1	x2	x3
2	1	3
8	4	7
1	4	4
2	8	2

고유값 목록:
[0.6541291, 14.33608183, 8.17645574]

고유값 크기 순선에 따른 주요 구성요소의 순서:
 $x2 > x3 > x1$



주요 구성 요소 2개를 추린다면,
97% 변화량을 반영하면서 3차원을 2차원으로 축소

x2	x3
1	3
4	7
4	4
8	2

두 속성이 전체 변화량의 97% 차지
 $(14.336+8.176) / (14.336+8.176+0.654)$

PCA를 이용한 데이터 압축 1/3

행렬 A ($m \times n$)

각 열의
평균벡터 ($1 \times n$)

편차 행렬
 dA ($m \times n$)

행렬 A의 공분산행렬을
고유값 분해

고유값

값1

값2

값n

고유
벡터

고유
벡터1

고유
벡터2

고유
벡터n

고유값이 큰 상위 k개의
벡터로 행렬 구성

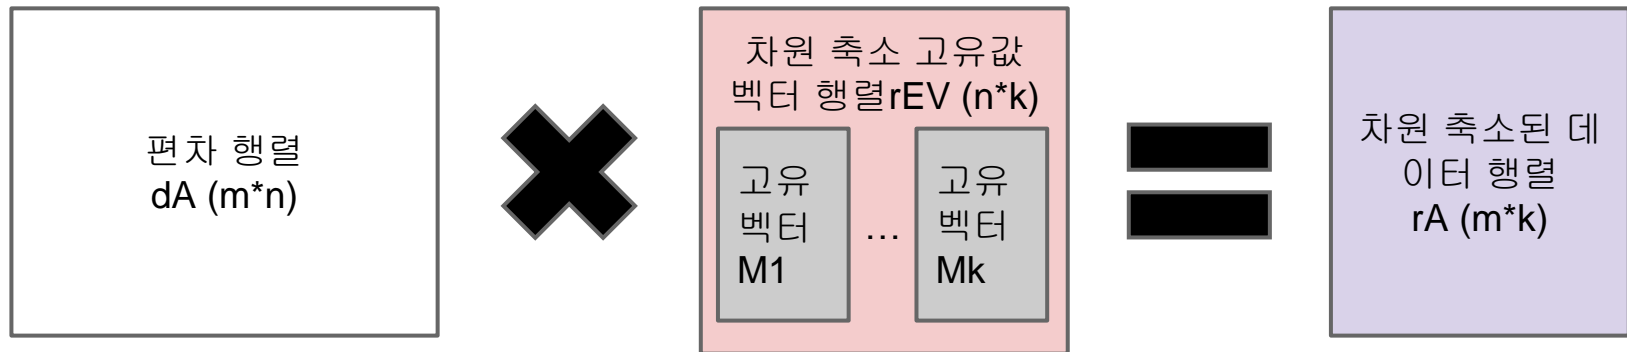
차원 축소 고유값
벡터 행렬 rEV ($n \times k$)

고유
벡터
M1

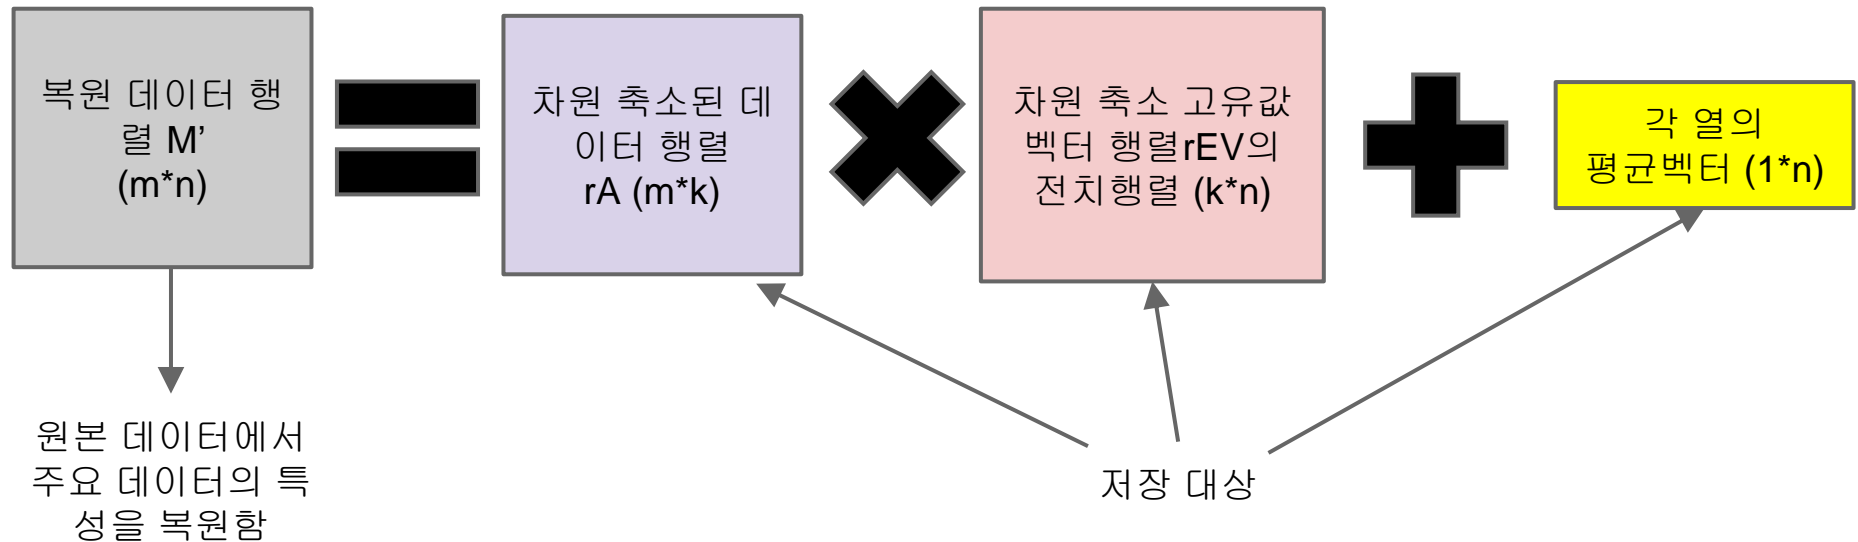
...

고유
벡터
Mk

PCA를 이용한 데이터 압축 2/3



PCA를 이용한 데이터 압축 3/3



2. SVD

특이 값 분해 singular value decomposition(SVD)

- 공식: $A = U\Sigma V^T$
 - A : $m * n$ 행렬
 - U : $m * m$ 직교 행렬 ($AA^T = U(\Sigma\Sigma^T)U^T$)
 - U 의 열벡터는 AA^T 의 고유벡터
 - V : $n * n$ 직교 행렬 ($A^TA = V(\Sigma^T\Sigma)V^T$)
 - V 의 열벡터는 A^TA 의 고유벡터
 - Σ : $m * n$ 특이 값 행렬!, 대각행렬
 - AA^T 와 A^TA 의 0이 아닌 고유값의 루트 값 목록
 - 값의 순서 $(1,1) > (2,2) > \dots > (n,n)$ ($m > n$ 경우)


* 직교 행렬: $AA^{-1}=AA^T=I$ 일 때, A 를 직교 행렬이라 함

* I 는 단위 행렬 (단위 행렬: $AI=IA=A$ 인 행렬 I , 대각선 1, 나머지 0)

* 대각 행렬: 대각선만 값을 갖고 나머지는 0인 행렬

SVD를 이용한 차원 축소: 데이터 축소

$$A_{m \times n} = U_{m \times m} * \Sigma_{m \times n} * V_{n \times n}^T$$




$$A_{m \times n} = U_{m \times k} * \Sigma_{k \times k} * V_{k \times n}^T$$

원본 데이터를 복원하는 데 필요한 데이터,
이미지 압축 등에 활용

SVD를 이용한 차원 축소: 열 차원 축소

$$A_{m \times n} = U_{m \times m} * \Sigma_{m \times n} * V^T_{n \times n}$$




열의 개수를 줄여서, 행 간
비교 연산 비용 낮춤.
행 간 유사도 연산 비용을
낮추는데 활용

$$A'_{m \times k} = U_{m \times k} * \Sigma_{k \times k}$$

SVD를 이용한 차원 축소: 행 차원 축소

$$A_{m \times n} = U_{m \times m} * \Sigma_{m \times n} * V^T_{n \times n}$$

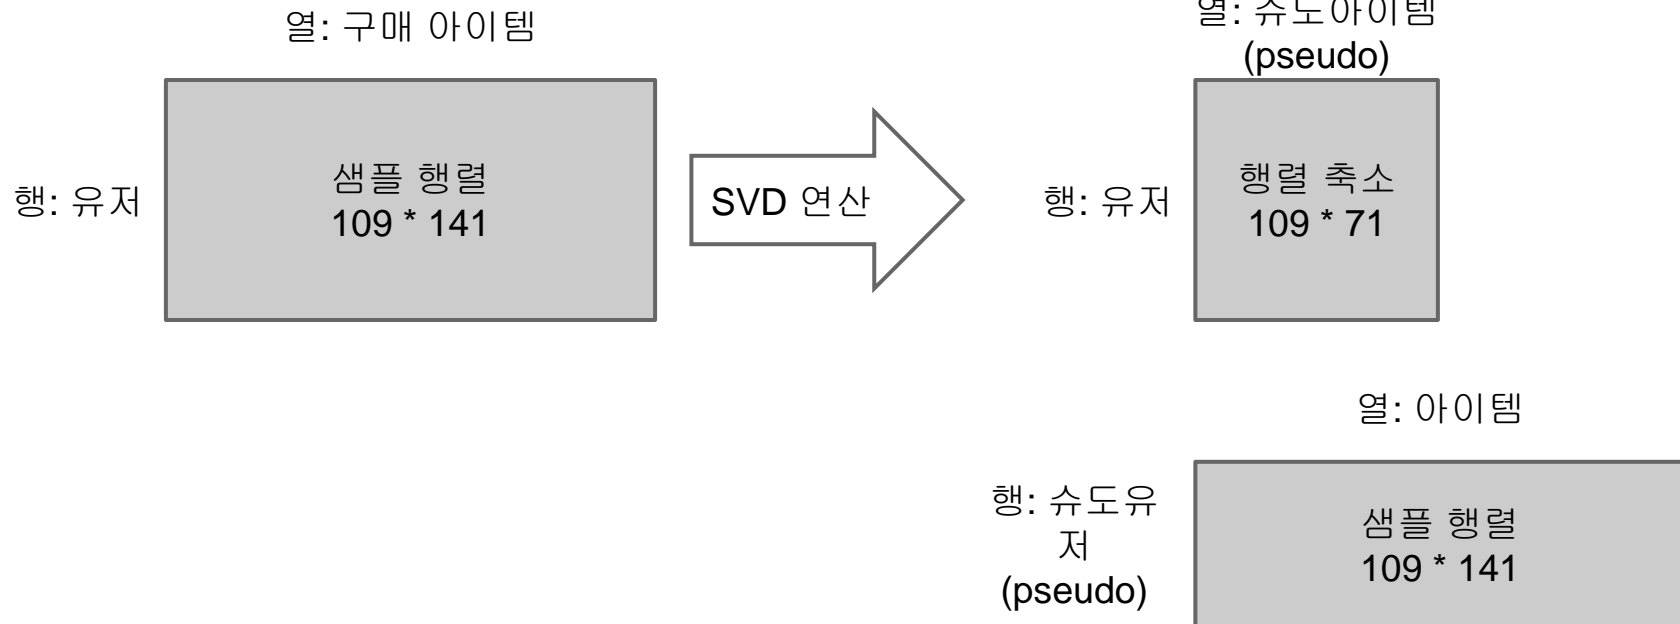


행의 개수를 줄여서, 열 간
비교 연산 비용 낮춤.
열 간 유사도 연산 비용을
낮추는데 활용

$$A'_{k \times n} = \Sigma_{k \times k} * V^T_{k \times n}$$

SVD 적용 예, 유사도 분석을 위한 축소

90%를 넘기는 특
이값은 71개



3. NMF

독립 특성

- 여러 데이터 중에서 주요 독립 특성을 이루는 데이터는?
 - 예,
 - 기사들 중에서 주제(독립 특성)들을 뽑아내고, 각 주제에 해당하는 기사 찾기
- 비음수 행렬 인수분해
 - NMF(Non-negative Matrix Factorization)
 - 독립 특성 추출 기법 중 하나

NMF

- 행렬 V 가 있을 때, V 를 $W \times H = V$ 인 두 행렬 W 와 H 로 분해

출처: 위키피디

인수분해 알고리즘 (증배 갱신 규칙 **multiplicative update rule** 사용)


1. W, H 에 임의 값을 채움
2. $W \times H$ 와 V 가 유사해 질 때까지 아래 과정 반복
 - a. H 행렬 갱신
 - i. $HN = W^T * V, HD = W^T * W * H + 0.000000001$
 - ii. $H(r,c) = H(r,c) * HN(r, c) / HD(r,c)$
 - b. W 행렬 갱신
 - i. $WN = V * H^T, WD = W * H * H^T + 0.000000001$
 - ii. $W(r,c) = W(r,c) * WN(r,c) / WD(r,c)$

NMF의 해석

W의 각 열이 특성이 됨:

- 열 길이가 2일 때 특성 f1, f2가 존재

W의 각 행은 V의 같은 행이 '특성에 얼마나 적합'한지(즉, 특성에 대한 가중치)를 나타낸다.



H의 각 행이 특성이 됨:

H의 각 열은 V의 같은 열이 '특성에 얼마나 중요'한지를 나타낸다.

NMF를 독립 특성 발견에 활용

- 예, 온라인 기사의 주제 찾기

$$\begin{matrix} & \text{특성1} & \text{특성2} & \text{특성3} \\ \begin{matrix} \text{기사1} \\ \text{기사2} \\ \text{기사3} \\ \text{기사4} \end{matrix} & \begin{bmatrix} W \end{bmatrix} & \times & \begin{matrix} \text{특성1} \\ \text{특성2} \\ \text{특성3} \end{matrix} \begin{bmatrix} H \end{bmatrix} & = & \begin{matrix} \text{기사1} \\ \text{기사2} \\ \text{기사3} \\ \text{기사4} \end{matrix} \begin{bmatrix} V \end{bmatrix} \end{matrix}$$

가중치 행렬:

- 각 특성이 기사에 얼마나 적합한가?
- 각 열에서 값이 높은 기사n개가 해당 특성을 갖는 기사
- 각 행에서 값이 높은 특성n개가 기사를 잘 반영하는 특성

특성 행렬:

- 각 단어가 특성에 중요한 정도
- 각 행에서 값이 높은 단어 상위n개가 해당 특성을 대표하는 단어가 됨 (즉, 주제가 됨)

* 특성의 개수 선택이 분류에 영향

NMF 활용 예, 구매자 금액대별 성향

